

Correcciones para implementar el informe v6 y el Plan de Corrección

Big Data y Analítica de Datos · UPAO 2026-20 · Repositorio BIG_DATA-PROYECTO-COSTA-GAS (rama main, commit 41d7230) · Contrastado con Proyecto_BigData_CostaGas_Trujillo_final_v6.docx y Plan_Correccion_Bases_Proyecto_CostaGas.docx (8/10/2026).

1. Veredicto

El repositorio actual implementa el diseño del informe **anterior** y corre solo con datos sintéticos. El informe v6 cambió el modelo de datos, las señales, los indicadores y la arquitectura. Lo que sirve tal cual es la base técnica: rutas por LAKE_URI, parámetros en config.py, manifiesto, escritura Parquet, reglas de calidad como código, validación de RUC y pruebas. Lo que hay que rehacer es todo lo que depende del dato: esquemas, limpieza, tablas Silver, Gold, señales, modelos y KPIs.

Tema	Repositorio hoy	Informe v6 y Plan de Corrección
Fuentes internas	4 fuentes con códigos y columnas supuestas (aba_02, com_19, dis_01, red_02)	35 archivos D01–D35, 37 fuentes lógicas F01–F37, 17 tablas Silver, diccionario v3.0
Datos de prueba	Muestra sintética generada por muestra.py; las evidencias versionadas salen de ella	Datos reales; sin sintéticos salvo la réplica de escalabilidad; muestra real enmascarada
Conciliación	Por (placa, fecha, producto): compras – ventas de la misma unidad	Imposible: ninguna placa de compras aparece en ventas. Dos niveles: planta × mes y unidad × mes por rol
Señales	S1, S4, S5, S7, S8, S10 con definiciones antiguas	S1–S12 con resolución, ventana y estado; S8 no resoluble; nueva S12
Indicadores	1 vista SQL (diferencia)	5 KPIs nuevos (Base B7)
Modelo base	z robusto de pct_diferencia	z robusto de log(S/ de combustible por tonelada), por rol
MapReduce	map → reduceByKey sobre RDD de Spark	Hadoop Streaming real en EMR (GDELT 2020 y balance), comparado con Spark
Spark	Escrito; verificado solo en memoria; el pipeline usa pandas	Glue 5.0: job semanal con marcadores + job de externos con MLlib
Alertas	Parquet	Tabla Apache Iceberg con MERGE del estado de revisión
Reglas del repo	CLAUDE.md prohíbe EMR; PLAN.md sigue el informe anterior	EMR transitorio de 1 nodo permitido; plan por paquetes WP

Prioridades: **P0** antes de entregar el hito parcial · **P1** Semanas 8–10 · **P2** Semanas 11–14. **Ref.** = hallazgo (A–D), base (B) o paquete (WP) del Plan de Corrección.

2. Reglas y gobierno del repositorio

ID	Cómo está hoy en el repositorio	Corrección · listo cuando...	Ref.	Prio.
G1	CLAUDE.md prohíbe EMR y exige trabajar sobre la muestra sintética.	Reescribir las reglas: EMR permitido solo transitorio, 1 nodo m5.xlarge, con auto-terminate; Iceberg y MLlib permitidos; prohibidos los datos sintéticos fuera de scaletest/ y de las pruebas unitarias. Listo cuando las reglas coinciden con la Tabla 2.5 del v6.	C1, B4	P0
G2	PLAN.md describe los pasos 0.1–4.4 del informe anterior.	Sustituirlo por los paquetes WP 0.1–3.5 del Plan de Corrección, con responsable, apoyo y fecha. Conservar el anterior en docs/historico/.	§4	P0
G3	10 ADR; ninguno recoge las decisiones del v6.	Nuevos ADR: EMR para MapReduce real; Iceberg en fact_alerta; dos niveles de conciliación; universo de datos cerrado; velocidad moderada (lote semanal, ventana de 15 min); retiro de TikTok y Facebook; muestra enmascarada; KMeans en MLlib.	B1–B11	P0
G4	Commits directos a main y nombres de rama libres.	Una rama por paquete (wp-0.2-silver-compras), PR revisado por el apoyo y el ID del paquete en el mensaje: feat(silver): WP 0.2 tabla compras_glp. Proteger main.	§5.1	P0
G5	Estructura src/...; el plan pide contracts/, ingest/, lambda_silver/, spark_gold/, iac/, sample_data/.	Decidir una y registrarla en un ADR. Recomendado: mantener src/ (evita romper imports y pruebas) y añadir contracts/, sample_data/ y src/mr/; documentar la equivalencia en el README.	§5.1	P1
G6	.gitignore excluye data/raw/, .env, *.xlsx; no excluye *.xls ni artifacts/.	Añadir *.xls y data/ completo; instalar un detector de secretos en pre-commit; revisar qué contiene artifacts/ antes de versionarlo.	§5.1, B8	P0

3. Datos de muestra y evidencias

ID	Cómo está hoy en el repositorio	Corrección · listo cuando...	Ref.	Prio.
D1	src/common/muestra.py genera datos sintéticos con anomalías inyectadas; el pipeline los usa por defecto.	Crear sample_data/ con un subconjunto real enmascarado (identificadores seudonimizados, sin nombres) generado por un script. El generador sintético queda solo como fixture de pruebas unitarias y nunca alimenta análisis ni modelos.	Tabla 1.1, B8	P0
D2	docs/evidencias/*.json csv md versionados provienen de la muestra sintética.	Retirarlos del repositorio y regenerarlos desde una corrida real, con fecha en el nombre. Listo cuando ninguna cifra de docs/evidencias/ proviene de datos sintéticos.	A1, B9	P0
D3	pipeline.py calcula «precisión contra la verdad sintética» y una etiqueta débil S1/S8.	Eliminar ambas. La validación pasa a ser documental (ver M3).	D3	P0
D4	linea_base.py calcula las métricas con pandas sobre Silver.	Calcular cada métrica desde Gold con una consulta de Athena guardada en sql/athena/queries/; el script en pandas queda como prueba de conciliación (mismos valores). Cada métrica declara capa, tabla, resolución, ventana, fórmula y valor.	A2, B6	P0

4. Ingesta y capa Bronze

ID	Cómo está hoy en el repositorio	Corrección · listo cuando...	Ref.	Prio.
I1	internos.py espera <proceso>/<codigo>/ con códigos inventados.	Prefijos por dominio de la Tabla 3.4b: compras/ ventas/ ventas_unidad/ gastos/ flota/ maestros/ produccion/ referencia/ y código de archivo d01...d35. Tabla de correspondencia archivo → dominio → código en un YAML.	Tabla 3.2	P0
I2	El manifiesto guarda hash, tamaño y filas totales; solo evita repetir la misma ruta.	Registrar hojas, filas leídas y filas efectivas por hoja ; rechazar un archivo cuyo hash ya existe aunque tenga otro nombre (D06 = D07); marcar las hojas de resumen que no pasan a Silver. Listo cuando el manifiesto reproduce 35 de 35 con hash, 1 duplicado y 181 694 filas efectivas de 2 279 609.	Tabla 2.2b, C4	P0
I3	No existen extractores externos.	Añadir: GDELT 2020 completo (zip diario → gzip en bloques de ≈ 128 MB), ENAHO, resoluciones de Osinermin de todo el país, Facilito, BCRP, padrón SUNAT, Registro de Hidrocarburos (PU-04) y precios de referencia (PU-05). Retirar TikTok y Facebook; YouTube opcional.	WP 1.5, 1.7, B5	P1
I4	No hay regla de borrado para GDELT.	Regla de ciclo de vida para bronce/externo/no_estructurado/gdelt/ (se borra tras filtrarse) y para emr-logs/ y sparkui/.	Tabla 2.7	P1

5. Contratos y limpieza (Bronze → Silver)

ID	Cómo está hoy en el repositorio	Corrección · listo cuando...	Ref.	Prio.
S1	schemas.py declara 4 fuentes en Python con columnas supuestas.	Un contrato YAML por tabla Silver en contracts/ generado desde el diccionario v3.0: nombre estándar, tipo, rol, regla y marca de dato personal. La Lambda, las reglas de calidad y el DDL leen el contrato. Listo cuando el DDL generado es igual al desplegado.	C5, B5, WP 1.1	P0
S2	Solo existen compras, ventas, flota y maestro.	Las 17 tablas de la Tabla 3.5b. Primero las prioritarias del hito: compras_glp, scop, ventas_detalle, ventas_unidad_mes, gastos, unidades; después pedidos, distribuidores, clientes, producción y consumo de tanques. Listo cuando los conteos en Athena igualan los del diccionario (1 541, 29, 28 618, 1 194, 16 323, 290).	WP 0.2, 1.2	P0
S3	normalizar_placa devuelve (placa, fecha) y no entiende sufijos ni paréntesis.	Versión del v6: quita sufijos (CAMION, CISTERNA, TRACTO...), separa la fecha entre paréntesis y devuelve (placa_norm, fecha, centro_costo) cuando el valor no es una placa (p. ej. «PLANTA»). Actualizar las pruebas.	Tabla 3.5	P0
S4	leer_crudo lee la hoja completa.	Cortar tras 3 000 filas vacías seguidas y exigir llave no nula. Medir tiempo antes y después: es la optimización real de 3.6 (PRIMAX: 522 filas útiles de 1 048 573).	C6, WP 0.5	P0
S5	Las fechas se convierten con to_datetime y nada más.	Comparar con el mes de la hoja; si coincide al invertir día y mes, invertir; si no, rechazar. Contar las corregidas (75 de 1 066).	Tabla 3.5	P0
S6	El tipo de cambio solo se marca si se desvía más de 1 %.	Rango válido 3.2–4.2; fuera de rango se imputa el T.C. oficial del día (PU-02) y se marca para S6. Rango en config.py.	Tabla 3.7	P0
S7	No hay conversión de unidades ni limpieza de totales.	kg = unidades × presentación; galones × 2.04 (sensibilidad 2.04–2.1, parámetro); litros × 0.54. Eliminar filas «TOTAL GENERAL». Esquema por posición para reportes sin encabezado y propagación del grupo (vendedor, proyecto). Columnas «*» por posición.	Tabla 3.5, B4	P0

ID	Cómo está hoy en el repositorio	Corrección · listo cuando...	Ref.	Prio.
S8	Cada archivo sobrescribe las particiones que toca.	Defecto real: si dos archivos alimentan la misma tabla y el mismo mes, el segundo borra al primero. Escribir una salida determinística por archivo y hash (origen=<hash>) o reconstruir la tabla completa desde todos sus archivos. Listo cuando reprocesar dos veces da el mismo resultado.	C4	P0
S9	Todo Silver se particiona por año/mes; el reporte es un JSON en silver/_calidad/.	Silver pequeñas en un solo Parquet; partición solo en hechos de Gold. Tabla de control silver/_control/ con una cifra por dimensión (validez, completitud, unicidad, consistencia, exactitud) y por tabla.	C2, WP 0.9	P1
S10	Las reglas no condicionan nada aguas abajo.	Una métrica de Gold no se publica si su fuente Silver está por debajo de la meta (Tabla 3.7). Añadir las reglas «SCOP presente» y «SCOP único».	B6	P1

6. Silver → Gold, Spark y MapReduce

ID	Cómo está hoy en el repositorio	Corrección · listo cuando...	Ref.	Prio.
P1	conciliacion.py concilia por (placa, fecha, producto) y produce fact_conciliacion_unidad.	Reemplazar por dos hechos: fact_balance_planta (anio, mes, producto; full_outer compras con ventas; es_mes_completo) y fact_unidad_mes (ventas por unidad con gastos; broadcast de unidades; rol; S/ de combustible por tonelada). Listo cuando may-2020 da 1.7–2.0 % y es el único mes completo.	B3, Tabla 4.9	P0
P2	El pipeline usa pandas por defecto; Spark no lee ni escribe Parquet en Windows.	Un solo script silver_to_gold.py ejecutable en Spark local y en Glue. En local: carpeta sin espacios y hadoop.dll o contenedor apache/spark:3.5. Fijar pyspark==3.5.* (igual que Glue 5.0).	C1, Tabla 3.2	P0
P3	El job de Glue no usa marcadores ni disparador.	Job semanal con marcadores de trabajo, disparador cron(0 11 ? * MON *), catálogo de Glue, Spark UI en S3 e Iceberg. Exportar gold/_mr_input/movimientos/ en texto para MapReduce.	D5, Tabla 2.2c	P1
P4	mapreduce.py hace MapReduce sobre RDD de Spark.	Añadir Hadoop Streaming real: mapper_gdelt.py, mapper_balance.py, reducer_suma.py (el reducer sirve de combiner) y steps.json. Probar en local con cat mapper sort reducer y después en EMR. Listo cuando el balance de MapReduce es idéntico al de Spark. La versión RDD se conserva como evidencia de reduceByKey frente a groupByKey.	WP 1.5b, Tabla 3.6b	P1
P5	No existe el job de datos externos.	Segundo job de Glue (5 trabajadores, pdfplumber): GDELT con DataFrames, PDF como binaryFile → texto, y temas con MLlib (RegexTokenizer, StopWordsRemover, CountVectorizer, LDA). Salidas: eventos_mercado_mes, resoluciones, quejas_marca_mes.	WP 1.5c	P1
P6	Las 8 uniones Spark de uniones.py no se usan y siguen la Tabla 3.6 antigua.	Reescribirlas según la nueva Tabla 3.6 (S12 con full_outer por proveedor + serie + número; S2 con left_anti; habilitadas con left_semi) y llamarlas desde el job de Gold.	WP 0.11	P0
P7	explain() solo se guardó en pruebas en memoria.	Guardar explain(True), capturas de Spark UI y tiempos en docs/evidencias/ con fecha. Medir: XLSX frente a Parquet en Athena, partition pruning, predicate pushdown, broadcast, cache, AQE, Spark frente a MapReduce, marcadores y bloques de 128 MB.	C8, WP 0.5, 1.4	P0
P8	replicar.py replica la tabla movimientos, que desaparece.	Replicar las tablas Silver reales a 10× y 100× en scaletest/ y añadir la parte con volumen real (GDELT 2020). Hito parcial: 1× y 10× en Lambda y Glue, con tiempo, memoria y costo.	WP 0.6	P0

7. Señales, modelos e indicadores

ID	Cómo está hoy en el repositorio	Corrección · listo cuando...	Ref.	Prio.
M1	senales.py implementa 6 señales con las definiciones antiguas, incluida S8.	Catálogo S1–S12 en YAML con resolución, ventana, estado y evidencia. Para el hito: S2, S3, S6, S7, S9, S11 y S12 (77 casos). S8 queda declarada «no resoluble». Lista de casos conocidos (10 sobrecobros F08, 4 SCOP corregidos F04, errores S12) como control.	B6, WP 0.8, 0.11	P0
M2	base_mad.py puntúa pct_diferencia y solo marca el lado positivo.	z robusto de log(S/ de combustible por tonelada) por rol, con z > 3.5. Reportar el resultado honesto: 0 de 82 unidad-mes en 2020, combinado con las señales determinísticas.	D2	P0
M3	La métrica es precision@20 contra una etiqueta débil.	Validación documental ciega: 20 alertas de mayor puntaje + 10 al azar, confirmadas solo si un segundo registro las respalda, revisadas por quien no construyó el modelo. Métricas: precision@20 documental, tasa base y recuperación de casos conocidos (≥ 0.70).	D3, WP 2.3	P1

ID	Cómo está hoy en el repositorio	Corrección · listo cuando...	Ref.	Prio.
M4	definitivo.py entrena por unidad-mes con scikit-learn.	Modelo principal por factura de compra (1 541 filas). Vector de características en MLlib (VectorAssembler, RobustScaler); Isolation Forest y LOF frente a KMeans por distancia en MLlib sobre el mismo vector.	D1, D4, WP 2.1–2.2	P1
M5	Solo existen dos hechos y ninguna dimensión.	Gold final: fact_balance_planta, fact_unidad_mes, fact_alerta y las dimensiones dim_tiempo, dim_unidad, dim_persona, dim_producto, dim_contraparte, dim_senal. fact_alerta como tabla Iceberg con MERGE del estado de revisión.	C3, WP 2.4	P2
M6	Una vista SQL sobre una tabla que deja de existir.	Cinco vistas: diferencia de planta (%), valor de la diferencia (S/), compras con segundo registro coincidente (%), combustible por tonelada, confirmación documental de alertas (%). Cada una con responsable y acción.	B7, A4	P1
M7	No hay notebook de análisis exploratorio.	Notebook sobre Silver y Gold con al menos 3 gráficos: compras frente a ventas por mes, Pareto de unidades y precio por canal, cada uno con pregunta e interpretación.	WP 0.7	P0

8. Infraestructura y seguridad

ID	Cómo está hoy en el repositorio	Corrección · listo cuando...	Ref.	Prio.
A1	No hay cuenta de AWS configurada; <code>stack.yaml</code> nunca se validó.	Crear la cuenta, MFA en la raíz, un usuario de IAM por integrante, <code>aws configure</code> y la sal en SSM. Validar y desplegar. Listo cuando hay logs de CloudWatch, listado de S3 y una consulta en Athena de una corrida real.	WP 0.2	P0
A2	El stack tiene un solo job de Glue, sin disparador, y ningún recurso de EMR.	Añadir: job de externos, disparador semanal, marcadores, <code>--datalake-formats iceberg</code> , prefijos <code>scripts/</code> , <code>sparkui/</code> , <code>emr-logs/</code> . EMR se lanza con la CLI (<code>aws emr create-cluster ... --auto-terminate</code>), no desde el stack: registrar la excepción en un ADR.	Tabla 2.2c	P1
A3	El rol de Lambda lee todo <code>bronze/</code> ; el de Glue no lee <code>bronze/externo/</code> completo.	Lambda: solo <code>bronze/interno/</code> → <code>silver/</code> . Glue: <code>bronze/externo/</code> y <code>silver/</code> → <code>silver/</code> y <code>gold/</code> . Políticas JSON en <code>infra/iam/</code> . Tabla de equivalencias Kerberos ↔ IAM y Ranger ↔ políticas por prefijo.	C7, WP 1.6	P1
A4	La Lambda no tiene capa con <code>openpyxl</code> ; Budgets avisa a un solo correo.	Añadir la capa para leer XLSX, memoria de 1 a 3 GB y los cuatro correos en el presupuesto. Confirmar el ARN vigente de la capa de pandas.	Tabla 2.2c	P0
A5	El costo estimado no considera EMR ni GDELTA.	Nuevo estimado ≈ US\$ 0.86 (EMR ≈ 0.12, Glue ≈ 0.57). El margen es estrecho: usar Spot en EMR si se acerca a US\$ 1 y registrar el costo real de Cost Explorer.	Tabla 2.7, WP 3.3	P1

9. Admisibilidad e informe

ID	Cómo está hoy en el repositorio	Corrección · listo cuando...	Ref.	Prio.
R1	El README explica la corrida con la muestra sintética.	README reproducible con la muestra real enmascarada. Listo cuando un tercero clona y corre el pipeline en menos de 15 minutos.	WP 0.1	P0
R2	No hay constancia de la empresa, ficha de las 35 fuentes ni declaración de IA.	Constancia firmada y ficha de procedencia en anexos. Anexo A firmado por los cuatro, con la tabla herramienta · uso · sección · verificación (declarar el uso de Claude Code en el código).	WP 0.3, 0.4	P0
R3	El informe está en futuro y tiene 56 páginas.	Reescribir en pasado con cifras, capturas y <code>explain()</code> ; máximo 35 páginas; figura 2.1 con lo que realmente corre; retirar «51 balanzas» si no tiene fuente; ninguna mención a datos por pedir.	A1, A3, A5, A6, WP 0.10, 0.12	P0

10. Orden de ejecución recomendado

Paso	Qué se hace	Correcciones	Desbloquea
1	Actualizar reglas, plan y ADR; proteger <code>main</code> ; retirar evidencias sintéticas	G1–G6, D2	Que todos trabajen sobre el v6
2	Cuenta de AWS, despliegue y manifiesto real de los 35 archivos	A1, A4, I1, I2	Bronze real
3	Contratos YAML y limpieza de las 6 tablas prioritarias; Lambda idempotente	S1–S8	Silver real y conteos del diccionario
4	Balance de planta y unidad-mes en Spark; uniones nuevas	P1, P2, P6	Gold y cifra de may-2020
5	Señales S2, S3, S6, S7, S9, S11, S12 y z robusto por rol	M1, M2	Modelo base del hito

Paso	Qué se hace	Correcciones	Desbloquea
6	Mediciones, escalabilidad 1× y 10×, notebook, métricas desde Athena	P7, P8, M7, D4	Secciones 3.6, 3.7, 4.1 y 4.2
7	Admisibilidad e informe	R1–R3, D1	Entrega del hito parcial
8	Semanas 8–14: 17 tablas, externos, MapReduce en EMR, MLlib, Iceberg, tablero, ética	I3, I4, S9, S10, P3–P5, M3–M6, A2, A3, A5	Hito final

Regla de oro del Plan de Corrección: si una cifra del informe no se puede reproducir con un comando del README, la cifra se retira o se reproduce antes de entregar.